Cechy sygnału audio w dziedzinie czasu

Jest wiele cech, które charakteryzują sygnał audio. Generalnie możemy je podzielić na dwie kategorie: dziedzina czasu i dziedzina częstotliwości. W tym projekcie zajmiemy się jedynie cechami sygnału dźwiękowego w dziedzinie czasu. Przedstawionych zostanie szereg niskopoziomowych cech charakteryzujących sygnał. Cechy te mogą być ekstrahowane zarówno ze skompresowanych jak i nieskompresowanych sygnałów audio. Termin „audio" oznacza tu uniwersalny sygnał dźwiękowy do którego zaliczyć możemy: mowę, dialog, muzykę, śpiew, przekaz radiowy, ścieżka audio programu wideo, szum i skrzyżowania wyżej wymienionych.

Specyficzne cechy sygnału audio wykorzystywane głównie w systemach klasyfikujących. Ogólny schemat klasyfikacji sygnału audio wykorzystujący jego cechy możemy przedstawić za pomocą schematu:

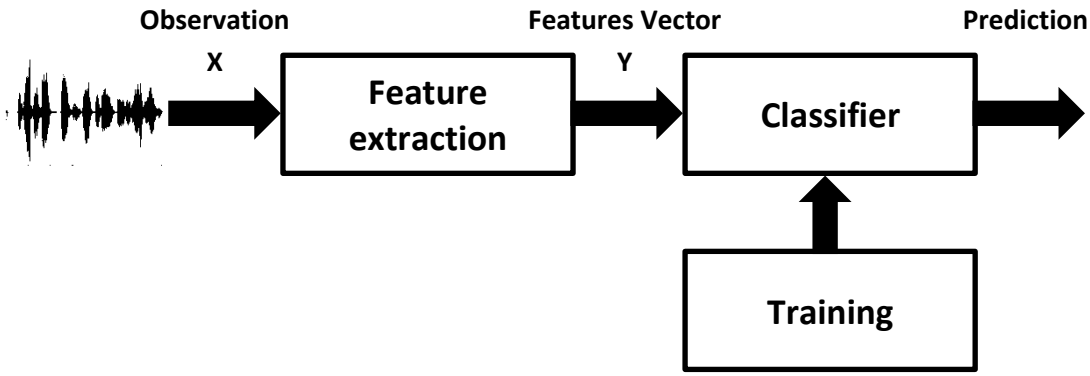

Cechy sygnału audio możemy zasadniczo podzielić na 2 grupy: krótkookresowe na poziomie ramki, długookresowe na poziomie klipu (kliku lub kilkunastu ramek). Ramka zdefiniowana jest tutaj jako grupa sąsiadujących ze sobą próbek których łączny czas trwania wynosi od 10 do 40ms. Dla cech których przeznaczeniem jest określenie zawartości semantycznej danego fragmentu sygnału audio niezbędne są większe fragmenty sygnału, zwykle od 1 do kilkudziesięciu sekund. Taki przedział jest nazywany klipem audio i zawiera on sekwencję ramek sygnału audio. Granice klipu audio mogą być rezultatem segmentacji pod względem podobieństwa cech pomiędzy poszczególnymi ramkami w danym klipie.

Cechy sygnału audio w dziedzinie czasu są wyliczanie bezpośrednio ze spróbkowanej fali dźwiękowej (amplitud) i określają czasowe właściwości sygnału audio.

1. Cechy sygnału audio w dziedzinie czasu na poziomie ramki (Frame-Level)

1.1. Volume – głośność

Miara ta wprowadza średnią głośność sygnału audio dla krótkich fragmentów i jest bardzo efektywna w detekcji ciszy oraz określania granic dla klipów audio. Głośność jest aproksymowana jako pierwiastek średniej energii sygnału audio w ramce:

$$p(n) = \sqrt{\frac{1}{N}\sum_{i=0}^{N-1} s_n^2(i)}$$

gdzie N oznacza długość ramki w próbkach, $S_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce.

Głośność sygnału audio zależy od ogólnej głośności całego nagrania na danym sprzęcie muzycznym. Aby wyeliminować wpływ sprzętu na ten współczynnik należy dokonać normalizacji.

1.2. STE (Short Time Energy)

Podniesienie głośności do kwadratu daje miarę określaną jako Short Time Energy (STE):

$$STE(n) = \frac{1}{N}\sum_{i=0}^{N-1} s_n^2(i) = p(n)^2$$

Podobnie jak głośność miara ta pozwala na rozróżnienie pomiędzy dźwięcznymi i bezdźwięcznymi fragmentami mowy. Wartości STE dla bezdźwięcznych fragmentów jest znacząco niższe niż dla dźwięcznych fragmentów.

1.3. ZCR – Zero Crossing Rate

Liczba przejść amplitudy przez zero w jednej ramce sygnału audio.

$$Z(n) = \frac{1}{2}\left(\sum_{i=1}^{N-1} |sign(S_n(i)) - sign(S_n(i-1))|\right)\frac{1}{N}$$

gdzie N oznacza długość ramki w próbkach, $S_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce, f_s jest częstotliwością próbkowania sygnału audio oraz *sing()* jest funkcją signum.

Miara ta jest wysoce efektywna w rozpoznawaniu dźwięcznych/bezdźwięcznych fragmentów mowy ponieważ typowa bezdźwięczna mowa posiada małą energię ale dużą wartość współczynnika ZCR. Kombinacja ZCR i głośności razem, pozwala klasyfikować bezdźwięczną mowę o niskiej energii jako ciszę.

1.4. SR – Silent Ratio

Miara ta wyliczana jest z głośności i ZCR. Jeżeli głośność (Volume) i ZCR dla ramki są poniżej pewnego poziomu, ramka taka może zostać zaklasyfikowana jako cisza.

1.5. Częstotliwość tonu podstawowego F0 (Fundamental Frequency)

Czasowa estymacja F0 bazuje na funkcji autokorelacji $R_n(l)$ lub funkcji AMDF (Average Magnitude Difference Function) - $A_n(l)$ wyliczanych z następujących wzorów:

$$R_n(l) = \sum_{i=0}^{N-l-1} s_n(i)s_n(i+l)$$

$$A_n(l) = \sum_{i=0}^{N-l-1} \left| s_n(i+l) - s_n(i) \right|$$

gdzie N oznacza długość ramki w próbkach, $S_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce.

2. Cechy sygnału audio w dziedzinie czasu na poziomie klipu (Clip-Level)

Cechy na poziomie ramki zostały zaprojektowane to wychwytywania krótkookresowych cech sygnału audio. Czasem jednak trzeba zaobserwować czasowe zmiany tych cech, szczególnie jeśli wymagana jest analiza semantyczna. To doprowadziło do zdefiniowania szeregu cech na poziomie klipu, które charakteryzują to jak cechy Frame-Level zmieniają się w klipie.

2.1. Bazujące na głośności

2.1.1. VSTD – Standard Deviation normalized by the maximum volume in a clip

Możliwe jest wyliczenie statystycznych miar z poszczególnych cech głośności dla całego klipu audio. Jednymi z tych miar mogą być: odchylenie standardowe normalizowane przez maksymalną wartość głośności w całym klipie (VSTD) lub średnia wartość głośności dla klipu.

2.1.2. VDR – Volume Dynamic Range

$$VDR = \frac{\max(v) - \min(v)}{\max(v)}$$

gdzie *min(v)* i *max(v)* są to minimalna i maksymalna głośność w całym klipie audio.

2.1.3. VU – Volume Undulation

Następną cechą jest Volume Undulation (VU – falistość głośności), która charakteryzowana jest poprzez nagromadzenie różnic sąsiednich pików i dolin dla konturu głośności w całym klipie.

2.2. Bazujące na energii

2.2.1. LSTER - Low Short Time Energy Ratio

Zdefiniowana jest jako odsetek liczby ramek w których STE są mniejsze niż 50 % średniej STE w oknie 1 sekundowym:

$$LSTER = \frac{1}{2N} \sum_{n=0}^{N-1} [\mathrm{sgn}(0.5 * avSTE - STE(n)) + 1]$$

gdzie *N* jest całkowitą liczbą ramek, *STE(n)* jest to STE w n-tej ramce, i *avSTE* jest średnią wartością STE w 1 sekundowym oknie.

Wartość LSTER jest efektywną miarą w rozróżnianiu mowa-muzyka. Biorąc pod uwagę to, że więcej ramek ciszy znajduje się w sygnale mowy niż w muzyce, miara LSTER dla mowy powinna być o wiele wyższa niż dla muzyki.

2.2.2. Energy Entropy

Następna cecha bazująca na energii, wyliczana poprzez podział każdej ramki audio w segmenty o K próbkach każdy. Energia sygnału jest wyliczana dla każdego fragmentu oraz normalizowana przez całkowitą energię ramki. Następnie, entropia energii I, dla klipu może być wyliczona ze wzoru:

$$I = -\sum_{i=1}^{J} \sigma_i^{\,2} \log_2 \sigma_i^{\,2}$$

gdzie J jest całkowitą liczbą segmentów w klipie i σ_i^2 jest znormalizowaną energią dla i-tego segmentu w klipie. Parametr entropii energii jest użyteczny w detekcji klipów audio zawierających „wybuchowe" sceny (detekcja scen przemocy, walki).

2.3. Bazujące na ZCR

2.3.1. ZSTD – Standard Deviation of the ZCR

Z niektórych badań wynikała użyteczność parametru ZSTD w rozróżnianiu kategorii programów telewizyjnych. Inne badania pokazywały, że statystki ZCR mogą zostać użyte dla klasyfikacji segmentów audio na 2 klasy: mowa i muzyka z dość wysokim współczynnikiem dokładności.

2.3.2. HZCRR – High Zero Crossing Rate Ratio

$$HZCRR = \frac{1}{2N} \sum_{n=0}^{N-1} [\mathrm{sgn}(ZCR(n) - 1.5 * avZCR) + 1]$$

gdzie *N* jest całkowitą liczbą ramek, *ZCR(n)* jest to ZCR w n-tej ramce, i *avZCR* jest średnią wartością ZCR w 1 sekundowym oknie.