Cechy sygnału audio w dziedzinie czasu

Zawada Igor, Łukaszyk Wojciech

2 kwietnia 2026

1 Opis aplikacji

Aplikacja służy jako narzędzie do niskopoziomowej analizy sygnałów audio zapisanych w formacie WAV. Program umożliwia ekstrakcję cech w dziedzinie czasu zarówno na poziomie ramki, jak i na poziomie klipu. Głównym celem aplikacji jest automatyczna segmentacja na fragmenty zawierające ciszę, mowę (dźwięczną i bezdźwięczną) oraz muzykę.

Aplikacja została zaprojektowana w języku **Python** przy użyciu następujących bibliotek:

- **PyQt5** – stworzenie interfejsu użytkownika (GUI) oraz obsługa odtwarzania.
- **NumPy** – zarządzanie próbkami audio i operacje matematyczne.
- **Wave** – niskopoziomowy odczyt danych z plików WAV.
- **Math** – standardowe obliczenia.
- **CSV** – eksport wyników.

Kod został podzielony na dwa moduły: `audio_features.py` (logika obliczeniowa, algorytmy ZCR, STE, Autokorelacja, AMDF, Energy Entropy) oraz `main.py` (interfejs użytkownika, renderowanie wykresów, wątek analizy).

2 Opis metod

2.1 Ramkowanie sygnału

Analiza rozpoczyna się od podziału sygnału na ramki o domyślnej długości **20 ms**. Przyjęto nakładanie się ramek (Hop) o wartości **10 ms**.

2.2 Cechy na poziomie ramki

Aplikacja wylicza następujące cechy na poziomie ramki:

- **Głośność (Volume)** – aproksymowana jako pierwiastek średniej energii sygnału w ramce (STE).

$$p_n = \sqrt{STE(n)} \tag{1}$$

  gdzie $STE(n)$ jest opisane poniżej.

- **STE (Short-Time Energy)** – suma kwadratów amplitud próbek w ramce, podzielona przez ich liczbę.

$$STE(n) = \frac{1}{N}\sum_{i=0}^{N-1} s_n^2(i) \tag{2}$$

gdzie $s_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce.

- **Zero Crossing Rate (ZCR)** – określa częstotliwość przecinania osi zero przez sygnał.

$$Z_n = \frac{1}{2}\sum_{i=1}^{N-1} |sign(s_n(i)) - sign(s_n(i-1))|\frac{1}{N} \tag{3}$$

- **Częstotliwość tonu podstawowego (F_0)** – estymowana metodą **Autokorelacji ($R_n(l)$)** polegającej na szukaniu podobieństwa sygnału do samego siebie oraz **AMDF ($A_n(l)$)** polegającej na minimalizacji różnicy amplitud.

$$R_n(l) = \sum_{i=1}^{N-l-1} s_n(i)s_n(i+l) \tag{4}$$

$$A_n(l) = \sum_{i=1}^{N-l-1} |s_n(i+l) - s_n(i)| \tag{5}$$

gdzie N - długość ramki w próbkach, $s_n(i)$ - aplituda i-tej próbki w n-tej ramce.

2.3 Cechy na poziomie klipu

Cechy te opisują dynamikę zmian sygnału w dłuższych przedziałach:

- **VSTD** - statystyczna miara zmienności głośności. Definiowana jako odchylenie standardowe głośności ramek podzielone przez głośność maksymalną.

$$VSTD = \frac{\sigma_p}{max(v)} \tag{6}$$

gdzie σ_p - odchylenie standardowe głośności, $max(v)$ - maksymalna głośność.

- **VDR (Volume Dynamic Range)** - dla klipu znajdowana jest maksymalna i minimalna głośność ramki w klipie. Miara zakresu dynamicznego obliczana jest według wzoru

$$VDR = \frac{max(v) - min(v)}{max(v)} \tag{7}$$

gdzie $max(v)$ - maksymalna głośnośc, $min(v)$ - minimalna głośność.

- **VU (Volume Undulation)** - opisuje dynamikę zmian sygnału w dłuższym przedziale czasowym. Charakteryzowana jest poprzez nagromadzenie różnic sąsiednich pików i dolin dla konturu głośności w całym klipie.

$$VU = \sum_{i=1}^{E-1} |e(i) - e(i-1)| \tag{8}$$

gdzie E - liczba ekstremów w całym klipie, $e(i)$ - głośność i-tego ekstremum.

- **LSTER (Low Short Time Energy Ratio)** – odsetek ramek z energią mniejszą niż 50% średniej energii w oknie 1-sekundowym.

$$LSTER = \frac{1}{2N} \sum_{n=0}^{N-1} [sgn(0.5 \cdot avSTE - STE(n)) + 1] \tag{9}$$

gdzie N - liczba ramek, $avSTE$ - średnia głośność w 1-sekundowym oknie.

- **Energy Entropy** – stopień uporządkowania zmian energii w ramce.

$$I = -\sum_{i=1}^{J} \sigma_i^2 log_2 \sigma_i^2 \tag{10}$$

gdzie J - całkowita liczba segmentów w klipie, σ_i^2 jest znormalizowaną energią dla i-tego segmentu w klipie.

- **HZCRR (High Zero Crossing Rate Ratio)** – udział ramek o bardzo wysokim współczynniku ZCR.

$$HZCRR = \frac{1}{2N} \sum_{n=0}^{N-1} [sgn(ZCR(n) - 1.5 \cdot avZCR) + 1] \tag{11}$$

gdzie N - całkowita liczba ramek, $ZCR(n)$ - ZCR w n-tej ramce, $avZCR$ - średnia wartość ZCR w 1-sekundowym oknie.

3 Algorytmy klasyfikacji

3.1 Detekcja ciszy

Cisza jest klasyfikowana na podstawie dwóch parametrów na poziomie ramki: Volume oraz ZCR. Ramka uznawana jest za ciszę jeśli oba parametry spadną poniżej pewnego progu. Ten próg dla Volume to połowa średniej głośności, a dla ZCR to 80% średniej wartości ZCR.

3.2 Podział na fragmenty dźwięczne i bezdźwięczne

Jeśli ramka nie została uznana za ciszę, klasyfikujemy ją jako ramkę dźwięczną lub bezdźwięczną.

- **Fragmenty dźwięczne (Voiced)** charakteryzują się niską wartością ZCR (poniżej 0.13) oraz obecnością wyraźnego tonu podstawowego F_0. Sprawdzamy czy autokorelacja lub funkcja AMDF pozwalają na wyznaczenie stabilnego tonu w przedziale od 70 Hz do 350 Hz.

- **Fragmenty bezdźwięczne (Unvoiced)** występują, gdy ramka ma stosunkowo niską energię (ale wyższą niż cisza) i bardzo wysoki współczynnik ZCR. W takich fragmentach algorytmy nie znajdują stabilnego tonu podstawowego.

3.3 Klasyfikacja mowa/muzyka

Mowa ma w porównaniu z muzyką wyższe wartości VSTD, VDR, VU, LSTER, HZCRR. Wynika to z jej zmienności.

Wartości VSTD, VDR oraz VU są wyższe w mowie, ponieważ ludzkie głosy mają wyraźne i nieregularne zmiany głośności wynikające z akcentowania, sylab i naturalnych pauz.

Ponieważ mowa jest mniej przewidywalna to wartości LSTER są większe. Energia dźwięku w muzyce zmienia się w bardziej przewidywalny sposób.

Mowa charakteryzuje się gwałtownymi zmianami ZCR (przejścia między głoskami dźwięcznymi a szumowymi spółgłoskami). Wysoki wskaźnik HZCRR jest typowy dla mowy.

Warunki, które przyjęliśmy żeby sklasyfikować fragment jako muzyka to:

- Wysoki udział ramek dźwięcznych w otoczeniu (powyżej 45%)
- Niski współczynnik HZCRR (poniżej 0.18)
- Małe odchylenie od głośności (VSTD $<$ 0.18)
- Brak silnych przesłanek wskazujących na mowę

Warunki, które przyjęliśmy żeby sklasyfikować fragment jako mowa to:

- Dominacja ramek bezdźwięcznych lub wysoki lokalny współczynnik ZCR
- Wysoki wskaźnik HZCRR lub LSTER (powyżej 0.4)
- Obecność częstych, krótkich fragmentów ciszy (Silent Ration powyżej 0.18)

Po przypisaniu wstępnych etykiet, wykonujemy jeszcze dwa kroki czyszczące.

- **Wykgładzanie** - krótkie serie ramek o jednej etykiecie w środku długiego bloku o drugiej etykiecie są usuwane i scalane z otoczeniem w celu uniknięcia "migotania"etykiet.
- **Etykieta ogólna** - jeśli obie klasy (speech i music) występują w podobnych proporcjach (powyżej 60% względem siebie) to nakładamy etykietę mixed.

4 Prezentacja wyników działania

Przed przystąpieniem do analizy poszczególnych plików audio ustalono parametry frame oraz hop jako odpowiednio 30ms oraz 15 ms dla każdej analizy.

4.1 Podział na voiced/unvoiced/silence oraz speech/music/silence

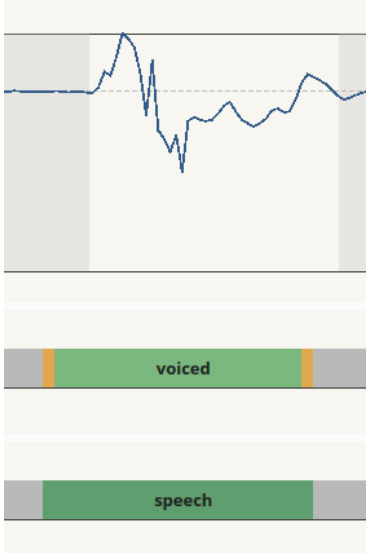

Rysunek 1: Analiza słowa "Jeden"wypowiedzianego przez mężczyznę

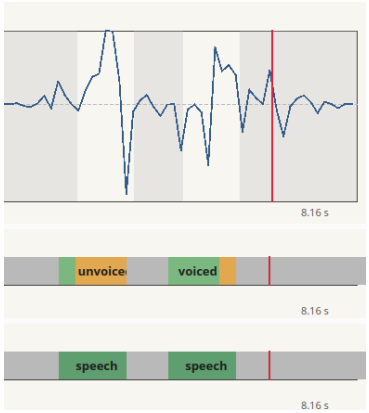

Rysunek 2: Analiza słowa "Jeden"wypowiedzianego przez kobietę

Obserwacje: W obu przypadkach analizowany fragment został poprawnie sklasyfikowany jako mowa (speech). W przypadku słowa „Jeden” wypowiedzianego przez mężczyznę widoczny jest bardziej zwarty i stabilny fragment dźwięczny (voiced), co wskazuje na wyraźniejszą okresowość sygnału w środkowej części wyrazu, natomiast krótkie odcinki na początku i końcu można interpretować jako przejścia lub słabiej okresowe fragmenty mowy. Dla nagrania kobiety segmentacja voiced/unvoiced jest bardziej rozdrobniona, a sam przebieg czasowy wykazuje większą zmienność, co sugeruje mniej stabilną strukturę okresową i utrudnia jednoznaczne wyznaczenie dźwięcznych części sygnału przez prosty algorytm. Szare obszary poprawnie wyznaczają ciszę przed i po wypowiedzi, dzięki czemu można łatwo oddzielić właściwy fragment słowa od tła.

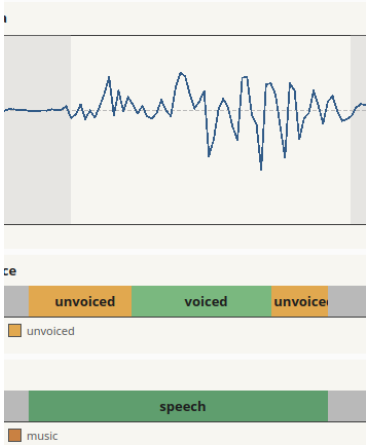

Rysunek 3: Analiza słowa "Trzy"wypowiedzianego przez mężczyznę

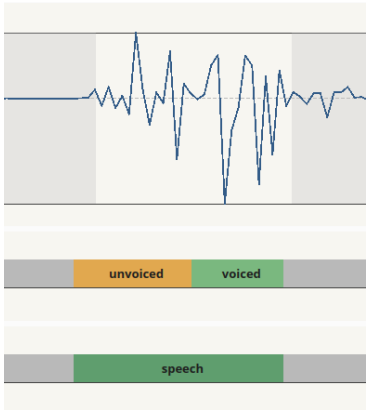

Rysunek 4: Analiza słowa "Trzy"wypowiedzianego przez kobietę

Obserwacje: Na podstawie przedstawionych wykresów dla słowa „Trzy” można zauważyć, że w obu przypadkach analizowany fragment został poprawnie sklasyfikowany jako mowa (speech), mimo że struktura sygnału różni się między nagraniem mężczyzny i kobiety. W pierwszym przypadku, dla głosu męskiego, widoczny jest centralny fragment voiced otoczony krótkimi odcinkami unvoiced, co dobrze odpowiada naturalnej budowie wypowiadanego słowa, w którym część głosek ma charakter bardziej okresowy, a część mniej regularny. W nagraniu kobiety również występuje fragment voiced, jednak poprzedzony jest wyraźniejszym odcinkiem unvoiced, a sam przebieg czasowy jest bardziej nieregularny i dynamiczny, co może wynikać z większej zmienności artykulacji oraz trudniejszego wyznaczania tonu podstawowego przez prosty algorytm. W obu przykładach szare obszary poprawnie wyznaczają ciszę przed i po wypowiedzi, a główny fragment słowa został dobrze odseparowany od tła. Ogólnie można stwierdzić, że dla słowa „Trzy” segmentacja voiced/unvoiced jest bardziej złożona niż dla prostszych, bardziej ciągłych fragmentów mowy, ale klasyfikacja całego segmentu jako speech pozostaje zgodna z rzeczywistą zawartością nagrań.

Rysunek 5: Analiza zdania "Dlaczego ta zima nie może się skończyć"wypowiedzianego przez mężczyznę

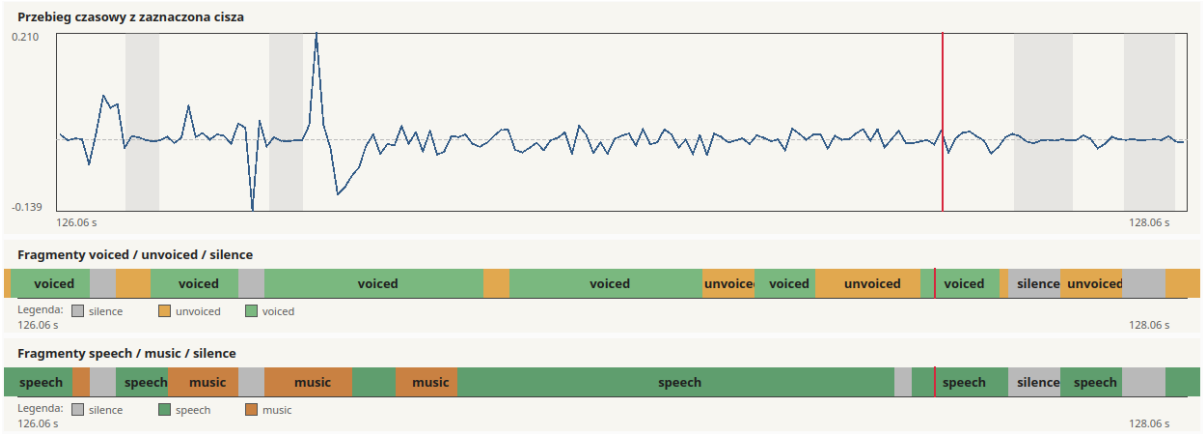

Rysunek 6: Analiza zdania "Dlaczego ta zima nie może się skończyć"wypowiedzianego przez kobietę

Obserwacje: Na podstawie przedstawionych wykresów dla zdania „Dlaczego ta zima nie może się skończyć” można zauważyć, że w obu przypadkach główny fragment nagrania został poprawnie rozpoznany jako mowa (speech), a algorytm poprawnie oddzielił aktywność sygnału od ciszy występującej przed i po wypowiedzi. W nagraniu mężczyzny przebieg czasowy jest bardziej równomierny, a segmentacja voiced/unvoiced pokazuje przewagę dłuższych fragmentów voiced, przerywanych krótkimi odcinkami unvoiced, co odpowiada naturalnemu przeplataniu się dźwięcznych i bezdźwięcznych elementów mowy ciągłej. W przypadku kobiety sygnał jest bardziej nieregularny, a podział voiced/unvoiced oraz speech/music jest bardziej rozdrobniony, pojawiają się także krótkie fragmenty zaklasyfikowane jako music, co można interpretować jako efekt większej zmienności sygnału i ograniczeń prostej heurystycznej klasyfikacji. Mimo tych lokalnych niedokładności dominującą etykietą pozostaje speech, co oznacza, że system poprawnie rozpoznaje ogólny charakter analizowanego nagrania. Ogólnie można stwierdzić, że dla dłuższych wypowiedzi algorytm zachowuje poprawność na poziomie całego zdania, choć w bardziej dynamicznych fragmentach pojawiają się pojedyncze błędne lokalne klasyfikacje.

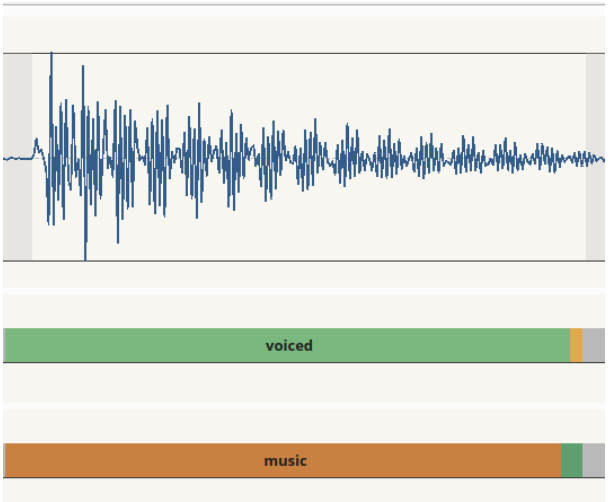

Rysunek 7: Analiza nuty E na 6 strunie gitary akustycznej

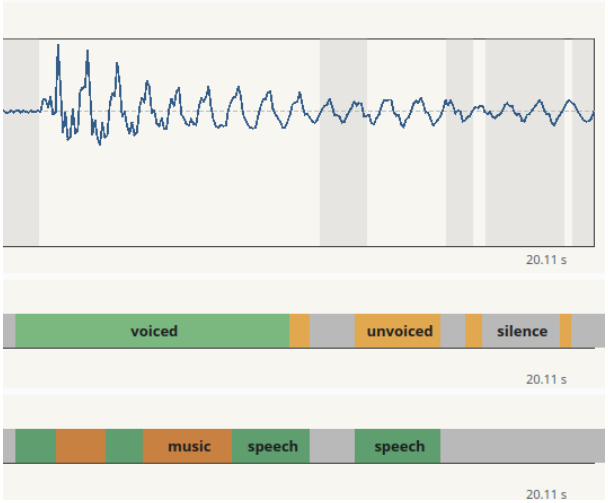

Rysunek 8: Analiza nuty E na 1 strunie gitary akustycznej

Obserwacje: Na podstawie przedstawionych wykresów dla pojedynczych dźwięków gitary akustycznej można zauważyć, że analiza poprawnie odróżnia sygnały instrumentalne od mowy, ponieważ dominującą etykietą w obu przypadkach jest music. Dla nuty E zagranej na 6 strunie przebieg czasowy ma wyraźny atak o dużej amplitudzie, po którym następuje stopniowe wygaszanie drgań, a segmentacja voiced/unvoiced wskazuje niemal cały dźwięk jako voiced, co jest zgodne z tonalnym, okresowym charakterem sygnału muzycznego. W przypadku nuty E zagranej na 1 strunie sygnał ma bardziej delikatny i regularny przebieg, jednak klasyfikacja jest mniej stabilna i pojawiają się krótkie fragmenty oznaczone jako unvoiced, silence, a nawet lokalnie speech, co można tłumaczyć większą wrażliwością prostego algorytmu na słabszy sygnał, zanik energii oraz drobne zmiany okresowości. Mimo tych lokalnych błędów dominującą interpretacją nadal pozostaje music, co oznacza, że system poprawnie rozpoznaje ogólny charakter analizowanych dźwięków instrumentalnych. Ogólnie można stwierdzić, że dla silniejszego i bardziej wyrazistego tonu klasyfikacja jest stabilniejsza, natomiast dla cieńszego i słabiej wybrzmiewającego dźwięku pojawiają się większe trudności z jednoznaczną segmentacją.

4.2 Metryki Volume/STE/ZCR/F0/Dominujące częstotliwości FFT

Poniżej przedtawione są przykładowe wykresy metryk dla poszczególnych fragmentów audio.

(a) Volume dla "Dziabba"

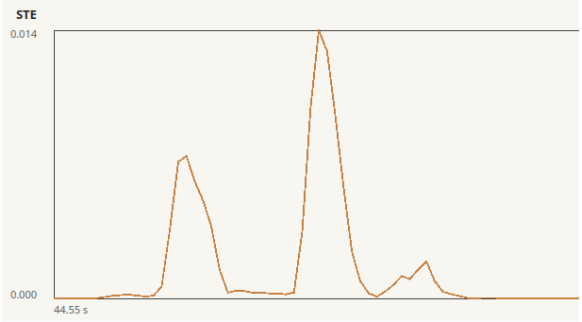

(b) STE dla "Dziabba"

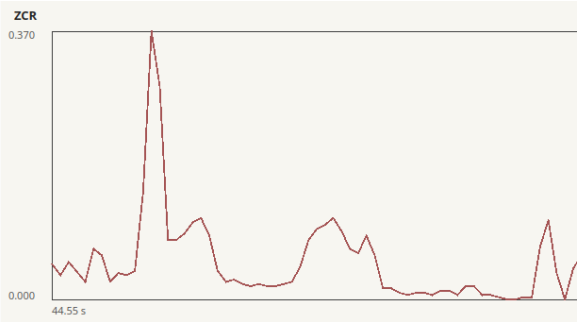

(c) ZCR dla "Dziabba"

(d) F_0 autokorelacja dla "Dziabba"

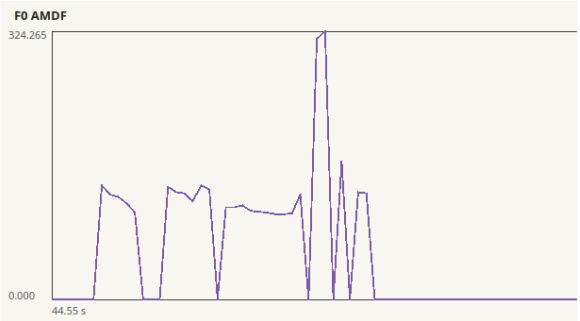

(e) F_0 AMDF dla "Dziabba"

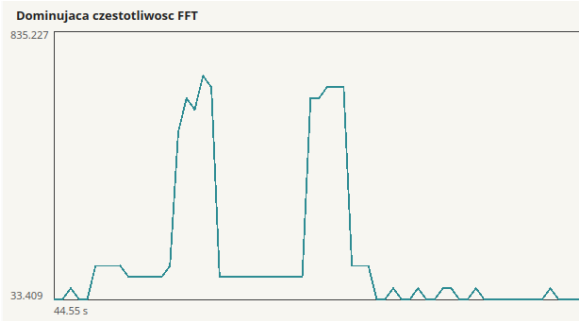

(f) Dominujące f wg. FFT dla "Dziabba"

Rysunek 9: Zestawienie cech sygnału w dziedzinie czasu dla słowa "Dziabba"wypowiedzianego przez mężczyznę

Obserwacje: Na wykresach widać, że słowo „Dziabba” ma kilka wyraźnych fragmentów aktywności, co potwierdzają piki Volume i STE, natomiast pomiędzy nimi energia sygnału wyraźnie spada. ZCR osiąga najwyższe wartości głównie w krótkich, bardziej szumowych lub przejściowych momentach, podczas gdy F_0 z autokorelacji i AMDF pojawia się tylko w bardziej okresowych, dźwięcznych częściach sygnału. Dominująca częstotliwość FFT również zmienia się skokowo w czasie, co pokazuje, że analizowane słowo nie ma jednolitej struktury, lecz składa się z kilku różnych faz artykulacyjnych.

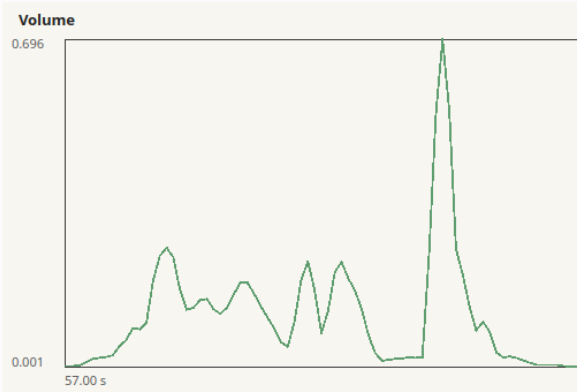

(a) Volume dla "samochód"

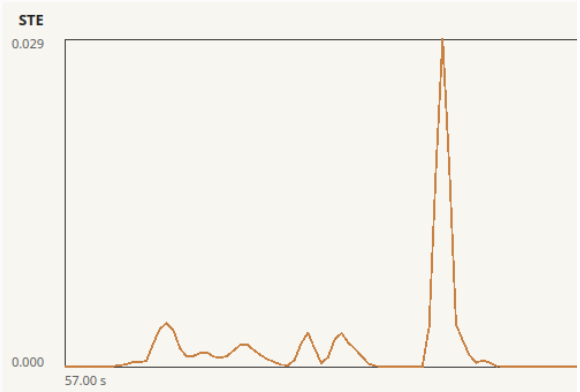

(b) STE dla "samochód"

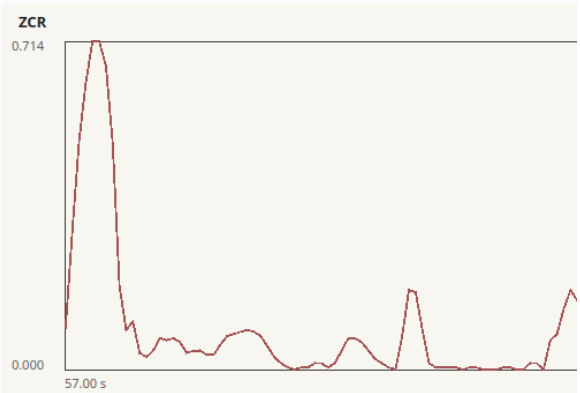

(c) ZCR dla "samochód"

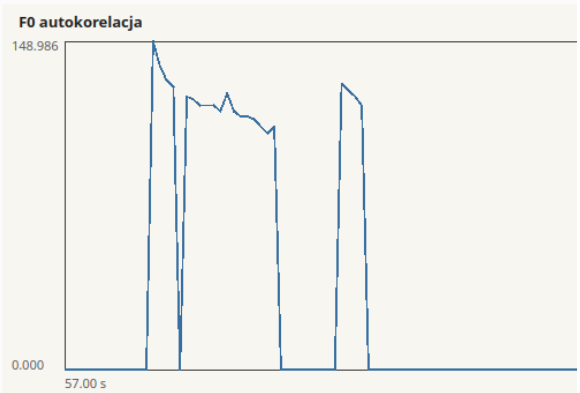

(d) F_0 autokorelacja dla "samochód"

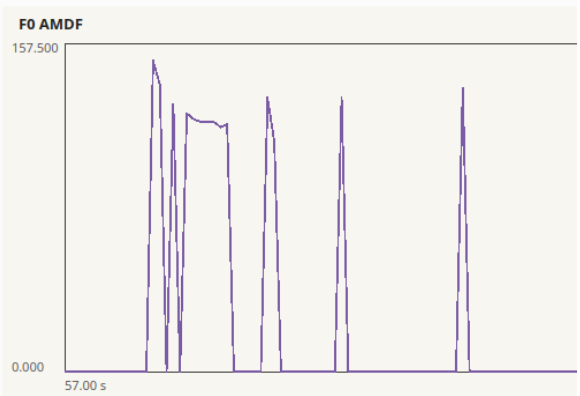

(e) F_0 AMDF dla "samochód"

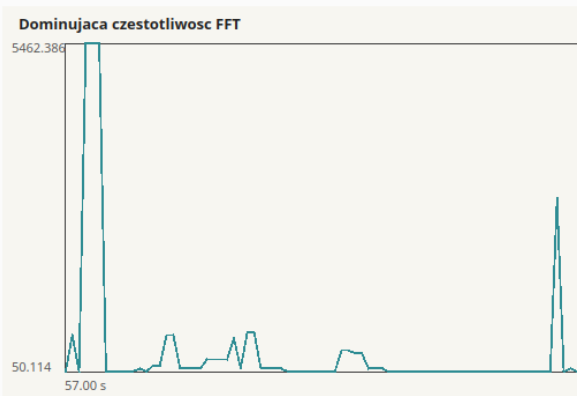

(f) Dominujące f wg. FFT dla "samochód"

Rysunek 10: Zestawienie cech sygnału w dziedzinie czasu dla słowa „samochód”

Obserwacje: Na wykresach dla słowa „samochód” widać nierównomierny rozkład energii, z wyraźnym silnym pikiem Volume i STE w końcowej części sygnału. ZCR jest bardzo wysokie na początku, co wskazuje na obecność bardziej szumowego lub bezdźwięcznego fragmentu, natomiast F_0 z autokorelacji i AMDF pojawia się głównie w częściach bardziej okresowych i dźwięcznych. Dominująca częstotliwość FFT również zmienia się skokowo, co potwierdza, że słowo ma złożoną strukturę i zawiera zarówno fragmenty dźwięczne, jak i przejściowe lub bezdźwięczne.

5 Wnioski

Na podstawie wykonanych analiz można stwierdzić, że nawet prosty program wykorzystujący podstawowe cechy sygnału audio pozwala uzyskać sensowne wyniki. Wyznaczone parametry, takie jak Volume, STE, ZCR, F_0 oraz dominująca częstotliwość z FFT, umożliwiły obserwację zmian sygnału w czasie oraz rozróżnienie fragmentów ciszy, mowy i dźwięków instrumentalnych.

Dla nagrań mowy algorytm w większości przypadków poprawnie rozpoznawał ogólny charakter sygnału jako speech. Dobrze widoczne były też fragmenty dźwięczne i bezdźwięczne, szczególnie w prostszych i wyraźniej wypowiedzianych słowach. W przypadku dłuższych wypowiedzi oraz niektórych nagrań kobiecych segmentacja była bardziej nieregularna, przez co pojawiały się pojedyncze błędne oznaczenia. Pokazuje to, że proste heurystyki działają poprawnie ogólnie, ale nie zawsze są bardzo dokładne lokalnie.

W analizie dźwięków gitary udało się zauważyć różnicę między mową a sygnałem muzycznym. Dla wyraźnych, stabilnych dźwięków klasyfikacja jako music była poprawna, szczególnie gdy sygnał miał wyraźny ton podstawowy i spokojny przebieg. Przy słabszych lub szybciej zanikających dźwiękach pojawiały się jednak krótkie błędne fragmenty oznaczone inaczej, co wynika z prostoty zastosowanych reguł.

Można też zauważyć, że poszczególne cechy opisują różne właściwości sygnału. Volume i STE dobrze pokazują miejsca, w których sygnał jest najsilniejszy. ZCR przydaje się do wykrywania fragmentów bardziej szumowych lub bezdźwięcznych. Z kolei F_0 działa najlepiej dla fragmentów okresowych, a w ciszy lub w sygnałach mniej regularnych często zanika. FFT była pomocna jako dodatkowa informacja o dominującej częstotliwości, ale nie zawsze dawała jednoznaczne wyniki.

Podsumowując, projekt spełnił swoje zadanie i pokazał, że podstawowe metody analizy audio mogą dawać użyteczne rezultaty. Wyniki są zgodne z intuicją i pozwalają lepiej zrozumieć, jak różne cechy opisują sygnał mowy i muzyki. Jednocześnie widać, że przy bardziej złożonych nagraniach dokładność prostych metod jest ograniczona.